

LAPORAN TEKNIS PROYEK FRESHLY
Deteksi Kondisi Kematangan Buah & Sayur



Disusun oleh

- **Zahra Ismaya (CDCC318D6X0757)**
- **Azzahra Fitri Ramadhanti (CDCC318D6X2436)**

Tim: CC26-PSU059
Coding Camp 2026

DAFTAR ISI

DAFTAR ISI	ii
RINGKASAN EKSEKUTIF	1
1. Problem Discovery.....	1
1.1 Latar Belakang	1
1.2 Pertanyaan Bisnis	1
1.3 Tujuan	2
3. Data Understanding	2
3.1 Sumber Data.....	2
1.2 Pre-Cleaning.....	2
4. Data Wrangling & Data Preparation	3
4.1 Gathering Data	3
4.2 Assessing Data.....	3
4.3 Cleaning Data.....	3
4.4 Splitting Data.....	3
4.5 Handling Imbalanced Data.....	4
5. Exploratory Data Analysis.....	4
5.1 Analisis Distribusi Data.....	4
5.2 Analisis Ukuran Gambar	4
5.3 Analisis Kualitas Gambar.....	5
5.3 Analisis Warna per Kelas	5
6. Feature Engineering.....	5
7. Visualizations and Explanatory Data	6
7.1 BQ-1: Distribusi & Representasi Dataset.....	6
7.2 BQ-2: Pola Warna	6
7.3 BQ-3: Overlap Fitur Warna Antar Kelas yang Mirip	7
7.4 BQ-4: Separabilitas Fitur HSV vs LBP.....	7
7.5 BQ-5: Dampak Proses Cleaning	7
8. A/B Testing	7
8.1 Strategi Augmentasi	7
8.2 Thresold Kualitas Gambar	8

8.3 Fitur Input Model	8
8.4 Split Ratio.....	9
9. Kesimpulan dan Saran	9
9.1 Kesimpulan.....	9
9.2 Saran.....	9
REFERENSI	11

RINGKASAN EKSEKUTIF

Data science pada proyek FRESHLY bertujuan membangun pipeline data berkualitas tinggi untuk klasifikasi otomatis kondisi kematangan buah dan sayur (*ripe*, *unripe*, *rotten*). Dataset awal terdiri dari 22.151 gambar dari 18 kelas (3 buah + 3 sayur). Melalui proses *data wrangling* dan *cleaning* yang sistematis, 971 gambar (4,4%) berhasil dieliminasi karena duplikasi dan kualitas visual buruk. Dataset akhir menghasilkan 21.180 gambar bersih yang didistribusikan ke split Train (80%), Validation (10%), dan Test (10%) secara *stratified*. Analisis *feature engineering* mengidentifikasi Green/Red (GR) Ratio dan Saturation Mean sebagai fitur paling diskriminatif untuk membedakan kondisi kematangan, dengan GR Ratio mencapai *separability score* tertinggi (2,034) untuk membedakan *ripe* dan *unripe*. Temuan ini menjadi pondasi penting untuk tahap pemodelan model AI.

1. Problem Discovery

1.1 Latar Belakang

Kualitas dan tingkat kematangan buah serta sayur merupakan faktor penting dalam menentukan kelayakan konsumsi, keamanan pangan, dan pengurangan limbah makanan (*food waste*). Namun, proses identifikasi kondisi kematangan masih banyak dilakukan secara manual berdasarkan pengamatan visual, sehingga sering kali bersifat subjektif dan kurang konsisten. Kesalahan dalam menentukan kondisi buah dan sayur dapat menyebabkan makanan dikonsumsi sebelum matang optimal, terlambat dikonsumsi hingga membusuk, atau bahkan terbuang meskipun masih layak makan.

Di sisi lain, perkembangan teknologi *computer vision* dan *deep learning* membuka peluang untuk membangun sistem klasifikasi otomatis berbasis citra yang mampu mengenali kondisi kematangan buah dan sayur secara lebih cepat, objektif, dan efisien. Sistem ini dapat membantu pengguna umum atau pelaku industri pangan dalam mengambil keputusan terkait konsumsi dan pengelolaan bahan pangan secara bijak (Tapia-Mendez et al., 2023).

Agar model *deep learning* dapat bekerja secara optimal, diperlukan proses pengolahan data yang sistematis dan berkualitas tinggi. Dataset gambar perlu melalui tahapan *data gathering*, *data assessing*, *cleaning*, *balancing*, dan *feature engineering* untuk memastikan bahwa data memiliki representasi visual yang baik dan relevan terhadap target klasifikasi. Selain itu, analisis fitur visual seperti warna dan tekstur juga diperlukan untuk memahami karakteristik yang paling berpengaruh dalam membedakan kondisi *ripe*, *unripe* dan *rotten*.

1.2 Pertanyaan Bisnis

1. Bagaimana distribusi kondisi *ripe*, *unripe*, dan *rotten* pada setiap jenis buah dan sayur dalam dataset? Apakah distribusi tersebut sudah cukup representatif untuk melatih model klasifikasi yang seimbang?

2. Apakah terdapat pola warna yang konsisten dan dapat diukur untuk membedakan ketiga kondisi kematangan berdasarkan analisis RGB channel dan Green/Red ratio?
3. Seberapa besar *overlap* fitur warna antar kelas yang secara visual mirip (*mango_ripe* vs *orange_ripe*, *mango_unripe* vs *tomato_unripe*, *paprika_ripe* vs *banana_unripe*), dan bagaimana potensinya mempengaruhi akurasi model?
4. Fitur visual apa (warna (HSV) atau tekstur (LBP) atau kombinasinya) yang paling efektif membedakan kondisi kematangan, dan seberapa besar kontribusi masing-masing fitur dalam memisahkan kelas?
5. Bagaimana proses *cleaning* data mempengaruhi kualitas dan representasi dataset akhir, dan berapa persentase data yang dieliminasi beserta alasannya?

1.3 Tujuan

Membangun *pipeline* data yang bersih, seimbang, dan kaya fitur sebagai fondasi untuk pelatihan model *deep learning* klasifikasi kondisi kematangan. Tahap ini mencakup data gathering, assessing, cleaning, splitting, oversampling, feature engineering, EDA, serta visualisasi untuk menjawab lima pertanyaan bisnis yang telah dirumuskan.

3. Data Understanding

3.1 Sumber Data

Dataset diunduh dari platform Kaggle dengan nama *capstone-raw-dataset* (tersedia untuk publik) yang mana gabungan dari berbagai sumber data citra mulai dari scrapping website penyedia gambar, Kaggle, Mendeley, hingga roboflow. Dataset ini merupakan koleksi gambar buah dan sayur yang dikumpulkan dari berbagai sumber untuk keperluan penelitian klasifikasi kematangan. Struktur folder utama dataset terdiri dari:

- **Fruits:** Berisi 9 kelas gambar buah: *banana*, *mango*, dan *orange*, masing-masing dengan subkelas *ripe*, *unripe*, dan *rotten*.
- **Vegetables:** Berisi 9 kelas gambar sayuran: *chili*, *paprika*, dan *tomato*, masing-masing dengan subkelas *ripe*, *unripe*, dan *rotten*.

1.2 Pre-Cleaning

Ditemukan masalah awal yang ada pada dataset yang dikumpulkan yaitu:

1. Inkonsistensi penamaan folder

Ditemukan folder *orange_unripe* yang memiliki *trailing space* (spasi di akhir nama folder). Hal ini menyebabkan label kelas terbaca salah saat proses *loading* awal.

2. Duplikasi konten

Terdeteksi sejumlah gambar dengan konten piksel identik namun nama file berbeda, terutama pada kategori sayuran.

3. Gambar berkualitas rendah

Beberapa gambar teridentifikasi memiliki kualitas visual yang buruk, seperti *blur*, *overexposed*, terlalu gelap (*dark*), distorsi geometris, atau ukuran file yang terlalu kecil (mengindikasikan kemungkinan *corrupt*).

4. Data Wrangling & Data Preparation

4.1 Gathering Data

Dataset mentah diunduh dari Kaggle menggunakan API Kaggle (kaggle datasets download), diekstraksi ke environment, dan dimuat ke dalam struktur data Python menggunakan OpenCV dan Pandas. Setiap gambar dibaca dari sistem file dan direkam sebagai entri dalam DataFrame dengan kolom path (lokasi file) dan label (nama kelas yang diambil dari nama folder).

Kerangka kerja *computer vision* untuk evaluasi pangan sebagaimana diuraikan dalam (Li et al., 2019) menyatakan bahwa langkah awal dalam sistem berbasis citra digital adalah *data acquisition* dan *pre-processing*, termasuk pemuatan gambar dan konversi ke format yang seragam sebelum analisis lebih lanjut. DataFrame yang dihasilkan berisi 22.151 entri gambar siap untuk proses *assessing*.

4.2 Assessing Data

Untuk mendeteksi duplikat konten (gambar dengan isi piksel identik tetapi nama file berbeda), diimplementasikan pengecekan menggunakan **MD5 hash** yaitu Metode ini tidak bergantung pada fitur gambar spesifik sehingga sangat cepat dan akurat untuk mendeteksi duplikat *eksak* (identik piksel demi piksel). Pendekatan *hash-based* merupakan alternatif yang menjanjikan untuk mendeteksi gambar duplikat, di mana *hash* dikonstruksi menggunakan serangkaian fitur unik yang diekstraksi dari gambar untuk identifikasi. Selain itu, algoritma berbasis MD5 untuk deteksi gambar duplikat telah terbukti efektif dalam berbagai aplikasi, termasuk dalam konteks WWW *image search engine* (Liu et al., 2014)

Fungsi `get_image_hash()` membaca file gambar dalam mode biner dan menghitung hash MD5-nya. Dua gambar yang menghasilkan hash yang sama dianggap duplikat konten. Proses ini diterapkan pada sampel per kelas dengan parameter `sample_per_class` yang disesuaikan (3000 untuk Fruits, 99999 untuk Vegetables untuk mencakup seluruh data).

4.3 Cleaning Data

Seluruh gambar yang ter-flag *distorted*, *small_file*, atau *low_res* dieliminasi menggunakan fungsi `clean_dataframe()`. Data test harus mewakili kondisi dunia nyata yang sebenarnya. Menghapus gambar "buruk" dari data test akan menciptakan *bias* evaluasi karena model hanya diuji pada gambar "sempurna". Oleh karena itu, *cleaning* hanya diterapkan pada data *train*. Persentase eliminasi total 4,4% (971 gambar dihapus).

4.4 Splitting Data

Dataset *clean* dibagi menjadi tiga subset: **Train (80%)**, **Validation (10%)**, dan **Test (10%)** karena ukuran dataset secara keseluruhan sedang, tapi distribusi per kelas tidak merata (Sadaiyandi et al., 2023). Pembagian dilakukan menggunakan fungsi `train_test_split` dari `scikit-learn` dengan parameter `stratify=df['label']` untuk memastikan proporsi setiap kelas terjaga di semua subset (Sadaiyandi et al., 2023). Proses ini dilakukan sebelum augmentasi untuk mencegah *data leakage* (gambar augmented tidak boleh masuk ke data validasi atau test).

Dalam dataset dengan distribusi kelas yang tidak seimbang sempurna, sehingga digunakan *stratified split* yang memastikan setiap subset memiliki proporsi kelas yang sama dengan dataset asli, sehingga evaluasi model menjadi lebih adil.

4.5 Handling Imbalanced Data

Melihat adanya imbalanced jumlah data yang, maka dilakukan *Oversampling* (augmentasi gambar) diterapkan **hanya pada data train vegetables** karena data train fruits sudah memiliki jumlah gambar yang cukup besar per kelas (rata-rata >1.100 gambar per kelas). Parameter `AUG_TARGET_MIN` diset ke **900 gambar per kelas** sebagai target minimal. Untuk setiap kelas yang jumlahnya di bawah target, dilakukan pembangkitan gambar baru menggunakan teknik augmentasi hingga target tercapai atau batas maksimum percobaan terlampaui. Augmentasi data secara signifikan meningkatkan akurasi model, terbukti pada penelitian (Kalabarige et al., 2024) dengan model hybrid (VT-DenseNet121) mencapai akurasi 99,57% setelah menggunakan dataset yang diperkaya dengan augmentasi.

Setiap gambar hasil augmentasi divalidasi dengan *blur score* ≥ 15 (menggunakan metode *Variance of Laplacian* yang sama seperti pada tahap *assessing*). Gambar yang terlalu *blur* dibuang dan digenerate ulang, untuk memastikan kualitas data augmented tetap terjaga.

5. Exploratory Data Analysis

5.1 Analisis Distribusi Data

Dilakukan analisis penyebaran dataset awal dengan menjumlahkan gambar per label dan memisahkan item dan kondisi dan dimuat dalam dataframe distribusi. Mengetahui distribusi data penting dilakukan karena ketidak seimbangan kelas dapat menyebabkan bias model (Sadaiyandi et al., 2023).

Berdasarkan analisis, ditemukan bahwa adanya ketidak seimbangan data pada beberapa kelas yang jumlah datanya <1000.

5.2 Analisis Ukuran Gambar

Menurut (Salim et al., 2024) untuk evaluasi kualitas citra digital, perlu melakukan perbaikan kualitas gambar. Maka dari itu, ukuran gambar. Dari hasil eksplorasi menggunakan scatter plot, diketahui bahwa:

- Rentang dimensi: ~60×70 px hingga 5000×7000 px

- Rata-rata Fruits: 612×667 px; Vegetables: 567×508 px
- Hampir semua gambar di atas ambang resolusi minimum.
- Variasi resolusi ekstrem, sehingga perlu *resize* ke ukuran standar sebelum pelatihan model.

5.3 Analisis Kualitas Gambar

Dilakukan analisis kualitas gambar, karena sistem evaluasi dalam cintra digital meliputi perbaikan kualitas gambar dan menghindari penghapusan false positive tanpa inspeksi visual (Li et al., 2019). Analisis kualitas gambar dilakukan dengan menganalisis distribusi kualitas gambar dari hasil *quality assessment* dengan hasil sebagai berikut:

- Blur: mayoritas > threshold 20, namun ada ekor distribusi (15% Fruits, 13,3% Vegetables), ini false positive dari background putih.
- Brightness: overexposed 6,3% (Fruits) karena background putih.
- Edge ratio: mayoritas dalam rentang normal, sedikit yang ekstrem.

5.3 Analisis Warna per Kelas

Melakukan ekstraksi rata-rata RGB per gambar (sample 50 per kelas), hitung GR ratio. Visualisasi box plot per item untuk red, green, dan GR ratio. Penggunaan red-green color ratio sesuai dengan penelitian (Rafie et al., 2024) yang digunakan untuk estimasi kematangan buah. Hasil analisis ditemukan:

- Ripe: GR = 0,826 (<1, dominan merah)
- Unripe: GR = 1,028 (>1, dominan hijau)
- Rotten: GR = 0,928 (variasi tinggi, mendekati 1)

6. Feature Engineering

Untuk menjawab BQ-2, BQ-3, dan BQ-4, perlu dilakukan ekstraksi fitur visual dari setiap gambar (sample 100 per kelas). Fitur-fitur yang diekstraksi dirancang untuk menangkap aspek warna dan tekstur yang relevan dengan kondisi kematangan

a. Fitur RGB

- **Red Mean:** rata-rata intensitas channel merah (0–255)
- **Green Mean:** rata-rata intensitas channel hijau (0–255)
- **Blue Mean:** rata-rata intensitas channel biru (0–255)
- **GR Ratio:** $\text{Green} / (\text{Red} + 1e-6)$, rasio yang menjadi indikator utama dominasi merah ($\text{GR} < 1$) atau hijau ($\text{GR} > 1$) yang merupakan hasil analisis dari EDA.

b. Fitur HSV (Hue, Saturation, Value)

Ruang warna HSV memisahkan informasi warna (*hue*) dari intensitas (*saturation* dan *value*), sehingga lebih dekat dengan persepsi manusia tentang

warna dan lebih robust terhadap variasi pencahayaan dibandingkan RGB (Rafie et al., 2024).

- **Hue Mean:** rata-rata warna dominan (0=merah, 60=kuning, 120=hijau, derajat OpenCV 0–179)
- **Hue Std:** variasi warna dalam gambar
- **Saturation Mean:** intensitas warna (tinggi = vivid/cerah; rendah = pucat)
- **Saturation Std:** variasi intensitas warna
- **Value Mean:** kecerahan gambar (0–255)
- **Value Std:** variasi kecerahan

c. **Fitur LBP (Local Binary Pattern) untuk Tekstur**

LBP dihitung dengan parameter $P=8$, $R=1$, $method='uniform'$. Nilai $P=8$ berarti 8 titik *sampling* di sekitar piksel pusat dengan radius $R=1$ piksel. Metode *uniform* mengelompokkan pola LBP ke dalam kelas-kelas terbatas sehingga menghasilkan histogram yang lebih stabil (Song et al., 2025).

- **LBP Mean:** rata-rata distribusi pola tekstur
- **LBP Std:** variasi tekstur (semakin tinggi, semakin kompleks tekstur permukaan)

7. Visualizations and Explanatory Data

7.1 BQ-1: Distribusi & Representasi Dataset

- Visualisasi distribusi kelas per item menggunakan **bar chart** (untuk Fruits dan Vegetables).
- Perhitungan dan visualisasi *imbalance ratio* (IR) per item dengan **horizontal bar chart**.
- Visualisasi komposisi persentase kelas per item dengan **stacked bar chart**.

Bar chart dan stacked barchart digunakan untuk memahami distribusi kategorikal seperti distribusi kelas per item dan komposisi persentase kelas per item SITASI. Sedangkan horizontal bar chart digunakan untuk visualisasi imbalance ratio karena sesuai untuk efisiensi ruang dan kemudahan membaca data kategorikal (Xiong et al., 2021).

7.2 BQ-2: Pola Warna

- **Box plot** per item untuk nilai Red, Green, dan GR ratio.
- **Violin plot** untuk melihat distribusi GR ratio per kondisi.
- **Heatmap** nilai rata-rata GR ratio per item dan kondisi.

Visualisasi *box plot* dan *violin plot* dengan pustaka seperti Seaborn adalah teknik standar dalam EDA untuk membandingkan distribusi fitur numerik di berbagai kategori SITASI. Dan visualisasi nilai rata-rata *Gain Ratio* (GR *ratio*) per item dan kondisi paling tepat menggunakan *Heatmap* (peta panas) karena grafik ini dirancang khusus untuk menemukan pola pada data dua dimensi secara instan (Rafie et al., 2024).

7.3 BQ-3: Overlap Fitur Warna Antar Kelas yang Mirip

- Analisis tiga pasangan kelas: (mango_ripe vs orange_ripe), (mango_unripe vs tomato_unripe), (paprika_ripe vs banana_unripe).
- Visualisasi dengan **scatter plot** (R vs G, GR vs Blue) dan **KDE plot** (GR ratio).
- Perhitungan **Overlap Score** dari histogram GR ratio.

Scatter plot dan KDE adalah alat visualisasi yang kuat untuk menilai tumpang tindih antar kelas dalam ruang fitur, dan merupakan bagian dari praktik standar EDA untuk mengidentifikasi potensi *confusion* sebelum pemodelan (Healy, 2024).

7.4 BQ-4: Separabilitas Fitur HSV vs LBP

- **Heatmap** Fisher Separability Score untuk 10 fitur pada tiga pasangan kelas.
- **Scatter plot** untuk menunjukkan pemisahan pada ruang fitur terbaik: GR ratio vs Hue Mean (warna), dan Saturation Mean vs LBP Std (tekstur).

Menampilkan skor pentingnya fitur dan pemisahan kelas dalam *scatter plot* adalah praktik umum untuk memvalidasi hasil *feature selection* dan memberikan wawasan tentang data. Sedangkan visualisasi *Fisher Separability Score* untuk 10 fitur pada tiga pasangan kelas paling tepat menggunakan *Heatmap* karena grafik ini mampu menyederhanakan matriks perbandingan multi-variabel menjadi satu tampilan yang intuitif (Gu, 2022).

7.5 BQ-5: Dampak Proses Cleaning

- **Bar chart** untuk meringkas jumlah data di setiap tahap (awal, duplikat, kualitas buruk, bersih).
- **Horizontal bar** untuk menunjukkan jumlah duplikat per kelas.
- **Bar chart** untuk perbandingan distribusi kelas sebelum dan sesudah cleaning.
- **Horizontal bar** untuk persentase eliminasi per kelas.

Penggunaan *bar chart* vertikal untuk meringkas jumlah data di setiap tahap sangat tepat karena format ini secara kronologis mampu menggambarkan efek penyusutan volume data dari awal hingga bersih secara sekuensial. Sementara itu, orientasi *horizontal bar chart* dipilih untuk visualisasi jumlah duplikat dan persentase eliminasi per kelas karena sumbu vertikalnya menyediakan ruang yang ideal bagi pelabelan nama kelas yang panjang tanpa risiko teks terpotong atau miring. Selain itu, format horizontal pada persentase eliminasi secara intuitif bertindak menyerupai *progress bar* yang memudahkan pembaca menilai tingkat keparahan reduksi data pada masing-masing kelas dari atas ke bawah (Xiong et al., 2021).

8. A/B Testing

8.1 Strategi Augmentasi

Hipotesis:

H0: Tidak ada perbedaan signifikan pada akurasi test antara split 80/10/10 dan 60/20/20 ($p \geq 0.05$)

H1: Salah satu split menghasilkan akurasi yang berbeda secara signifikan ($p < 0.05$)

Split 60/20/20 dipilih untuk membandingkan performa dikarenakan dengan 80/10/10 dan kelas paprika_unripe yang hanya ~325 gambar, test set-nya hanya ~33 gambar untuk kelas tersebut, yang mana jauh di bawah ambang 100 yang disarankan. Dengan 60/20/20, test set kelas tersebut menjadi ~65 gambar, masih kecil, tapi dua kali lebih stabil. Walaupun begitu, hasilnya tidak menunjukkan perbedaan signifikan, sehingga H0 gagal ditolak

8.2 Thresold Kualitas Gambar

Hipotesis:

H0: Perubahan blur threshold tidak berpengaruh signifikan terhadap akurasi model ($p \geq 0.05$)

H1: Setidaknya satu threshold menghasilkan akurasi yang berbeda secara signifikan ($p < 0.05$)

Sebuah studi tentang klasifikasi gambar medis menemukan bahwa akurasi model menurun seiring meningkatnya tingkat degradasi gambar, dan Gaussian blur menyebabkan penurunan performa paling signifikan dibanding jenis degradasi lain. Ditemukan pula korelasi linear yang kuat antara kualitas gambar dan akurasi deteksi, semakin baik kualitas gambar, semakin baik performa model (Lin et al., 2026)

Maka dari itu perlu diukur, apakah akurasi klasifikasi menurun setelah melewati batas blur tertentu, dan skor kepercayaan prediksi juga turun secara signifikan? Hasilnya Perubahan blur threshold tidak berpengaruh signifikan terhadap akurasi model sehingga H0 gagal ditolak.

8.3 Fitur Input Model

Hipotesis:

H0: Perubahan blur threshold tidak berpengaruh signifikan terhadap akurasi model ($p \geq 0.05$)

H1: Setidaknya satu threshold menghasilkan akurasi yang berbeda secara signifikan ($p < 0.05$)

Sebuah penelitian tentang klasifikasi gambar sayuran menemukan bahwa vektor fitur yang menggabungkan enam fitur warna dan enam fitur tekstur LBP menghasilkan akurasi klasifikasi 93.3%. Kombinasi fitur tersebut terbukti lebih efektif dibanding satu jenis fitur saja (Madgi et al., 2015).

Berdasarkan hasil, sistem pengenalan buah dan sayuran berbasis HSV color histogram dan LBP rotation-invariant texture feature terbukti berhasil pada implementasi embedded system Android sehingga H_0 gagal ditolak

8.4 Split Ratio

Hipotesis:

H_0 : Tidak ada perbedaan signifikan pada akurasi test antara split 80/10/10 dan 60/20/20 ($p \geq 0.05$)

H_1 : Salah satu split menghasilkan akurasi yang berbeda secara signifikan ($p < 0.05$)

Penelitian menunjukkan bahwa performa classifier dipengaruhi oleh variasi split ratio, dan penggunaan lebih dari 70% data untuk training cenderung memberikan performa lebih baik (Bichri et al., 2024). Namun ketika ukuran training meningkat dari 80% ke 90%, tren yang berlawanan ditemukan performa test justru menurun. Ini menunjukkan ada titik optimal yang tidak bisa ditentukan tanpa eksperimen (Nguyen et al., 2021).

Maka dari itu, dilakukan perbandingan pada split 80/10/10 dan 60/20/20, dan ditemukan bahwa dari kedua ratio split tersebut, tidak memberikan pengaruh signifikan terhadap performa model sehingga H_0 gagal ditolak.

9. Kesimpulan dan Saran

9.1 Kesimpulan

1. Data Cleaning: Proses *cleaning* berhasil mengeliminasi 4,4% data yang merupakan duplikat atau berkualitas buruk, terutama pada kelas paprika, sehingga meningkatkan kualitas dataset secara keseluruhan.
2. Feature Importance: GR ratio adalah fitur paling diskriminatif untuk membedakan *ripe* dan *unripe*, sementara saturation mean adalah kunci untuk mengidentifikasi kondisi *rotten*.
3. Tantangan Klasifikasi: Kelas *rotten* adalah yang paling sulit dikenali karena warnanya (GR ratio) sering tumpang tindih dengan kelas *ripe*. Overlap warna yang tinggi juga terjadi pada pasangan dengan warna yang mirip secara visual (misalnya, mangga matang vs jeruk matang).
4. Kesiapan Data: *Pipeline* data yang telah disiapkan, mencakup *cleaning*, *stratified splitting*, *oversampling*, dan ekstraksi fitur, sudah siap dan representatif untuk digunakan dalam pelatihan model *deep learning*.

9.2 Saran

Berdasarkan temuan di atas, rekomendasi untuk tim AI Engineer dalam tahap pemodelan adalah:

1. Gunakan Kombinasi Fitur: Jangan hanya mengandalkan RGB mentah. Manfaatkan fitur HSV (terutama *Saturation*) untuk memberikan informasi yang lebih stabil dan informatif.
2. Arsitektur Model: Gunakan arsitektur CNN dengan ukuran input standar (misal, 224×224). Pertimbangkan penggunaan model *pretrained* (seperti ResNet, EfficientNet) dengan *transfer learning*.
3. Penanganan Kelas *Rotten*: Berikan bobot yang lebih tinggi pada *loss function* atau gunakan teknik seperti *focal loss* untuk membantu model lebih fokus pada kelas minoritas yang ambigu ini.
4. Evaluasi Model: Perhatikan metrik seperti *precision*, *recall*, dan **F1-score**, terutama pada *confusion matrix* untuk pasangan kelas yang sulit dibedakan (*ripe vs rotten* dan *mango vs orange*).

REFERENSI

- Bichri, H., Chergui, A., & Hain, M. (2024). *Investigating the Impact of Train / Test Split Ratio on the Performance of Pre-Trained Models with Custom Datasets*. 15(2), 331–339.
- Gu, Z. (2022). Complex heatmap visualization. *Imeta*, 1(3), e43.
- Healy, K. (2024). *Data visualization: a practical introduction*. Princeton University Press.
- Kalabarige, L. R., Ramana, A. V., Rao, R. S., & Holla, M. R. (2024). Boosting Pineapple Maturity Classification: Impact of Data Augmentation and Visual Transformer Integration With Transfer Learning. *IEEE Access*, 12, 193263–193283. <https://doi.org/10.1109/ACCESS.2024.3519753>
- Li, Z., Ramesh, P., & Liu, C.-H. (2019). Image Quality Assessment Using Computer Vision. *Electronic Imaging*, 31(10), 317–1–317–1. <https://doi.org/10.2352/ISSN.2470-1173.2019.10.IQSP-317>
- Lin, C., Yoon, A. P., Wang, C., Chao, T., & Chung, K. C. (2026). *Effects of Image Degradation on Deep Neural Network Classification of Scaphoid Fracture Radiographs : Comparison Study of Different Noise Types*. 14, 1–18. <https://doi.org/10.2196/65596>
- Liu, J., Ling, H., Yan, L., & Ou, X. (2014). Feature fusion based hashing for large scale image copy detection. *Fifth International Conference on Intelligent Control and Information Processing*, 307–312. <https://doi.org/10.1109/ICICIP.2014.7010268>
- Madgi, M., Danti, A., & Anami, B. (2015). *Combined RGB colour and local binary pattern statistics features-based classification and identification of vegetable images Manohar Madgi **. 2(4), 340–352.
- Nguyen, Q. H., Ly, H., Ho, L. S., Al-ansari, N., Le, H. Van, Tran, V. Q., Prakash, I., & Pham, B. T. (2021). *Influence of Data Splitting on Performance of Machine Learning Models in Prediction of Shear Strength of Soil*. 2021. <https://doi.org/10.1155/2021/4832864>
- Rafie, A., el Berrouhi, S., Chenouni, D., Tahiri, A., & El Mallahi, M. (2024). AI-based feature parameters extraction from color images. *Multimedia Tools and Applications*, 83(17), 51715–51729.
- Sadaiyandi, J., Arumugam, P., Sangaiah, A., & Zhang, C. (2023). Stratified Sampling-Based Deep Learning Approach to Increase Prediction Accuracy of Unbalanced Dataset. *Electronics*, 12, 4423. <https://doi.org/10.3390/electronics12214423>
- Salim, D. A., Roza, Y. B., & Ramadhanu, A. (2024). Evaluasi Kualitas dan Kematangan Mangga Menggunakan Analisis Citra Digital dengan Euclidean Distance Fokus pada Buah Hijau dan Kuning. *Indonesian Journal Computer Science*, 3(2), 57–64.
- Song, Y., Sa, J., Luo, Y., & Zhang, Z. (2025). A comprehensively improved local binary pattern framework for texture classification. *Multimedia Tools and Applications*, 84(20), 22043–22068.

Tapia-Mendez, E., Cruz-Albarran, I. A., Tovar-Arriaga, S., & Morales-Hernández, L. (2023). Deep Learning-Based Method for Classification and Ripeness Assessment of Fruits and Vegetables. *Applied Sciences*, 13, 12504. <https://doi.org/10.3390/app132212504>

Xiong, C., Setlur, V., Bach, B., Koh, E., Lin, K., & Franconeri, S. (2021). Visual arrangements of bar charts influence comparisons in viewer takeaways. *IEEE Transactions on Visualization and Computer Graphics*, 28(1), 955–965.